



Inteligência Artificial aplicada ao Processo de Integração Terreno, Condições Meteorológicas, Inimigo e Considerações Civis (PITCIC)

Autores

João Victor Paim de Cerqueira Melo de Souza • Luan Siviero Passos

Orientadores

Prof. Anderson Fernandes Pereira dos Santos, Ph.D. • Maj. Pablo Gustavo Cogo Pochmann, M.Sc.

Sumário

- | | | | |
|-----|-------------------------------------|-----|--|
| 01. | Onde paramos | 07. | Série de experimentos |
| 02. | O limite da segmentação indireta | 08. | Modelo base |
| 03. | Objetivos atualizados | 09. | Domínio alvo: CBERS-4A |
| 04. | Metodologia | 10. | Construção do conjunto anotado |
| 05. | Base DeepGlobe e escala de trabalho | 11. | Estado atual e próximos passos |
| 06. | Fusão de classes | 12. | Trabalho paralelo: reservatório quântico |

O que é o PITCIC

Processo de Integração Terreno, Condições Meteorológicas, Inimigo e Considerações Civas

- **Contexto (Fases 1 a 3):** Consolidação de dados sobre o ambiente, clima e perfil doutrinário da ameaça.
- **Fase 4:** Integração final onde o **terreno** dita as possibilidades de manobra.
- Conversão de restrições físicas (relevo, vegetação, solo) em **Corredores de Mobilidade e Vias de Acesso**.
- **Previsão de Linhas de Ação (L Aç):** Antecipação da intenção do inimigo (Mais Provável vs. Perigosa) através da leitura das oportunidades oferecidas pelo terreno.
- **Inteligência Preditiva:** Uso de padrões geográficos históricos para prever o comportamento de ameaças desconhecidas em novos cenários.

Contexto: O Macro Projeto

Modernização no Exército Brasileiro

Automação do Processo de Integração Terreno, Condições Meteorológicas, Inimigo e Considerações Civis (PITCIC) através de IA agentiva.

Arquitetura do Macro Projeto

- Baseada em **LLMs** e comunicação multiagente.
- Uso de **RAG** para consulta a bases de conhecimento.
- Mapeamento de calcos de restritividade pressupõe mapeamento completo do terreno (cartas de relevo, hidrografia, etc.).

Contexto: O Macro Projeto - Lacuna

- **Acurácia:** Modelos de propósito geral distribuem sua capacidade representacional entre domínios distintos, o que limita a profundidade das características aprendidas para qualquer tarefa específica.
- **Custo computacional de inferência:** LLMs possuem dezenas a centenas de bilhões de parâmetro. Modelos de visão leves, como as arquiteturas CNNs podem realizar inferência em milissegundos mesmo em hardware modesto, **possibilitando a inferência local**.



Análise de Terreno



Inferência de
Restritividade



Previsão de Linhas
de Ação

O "Mundo Ideal"

Modelo de Previsão de Dificuldade

- Predição precisa de custo de movimentação tática
- Integração de variáveis de terreno em tempo real


Necessidade: Datasets Multimodais

- Fusão de dados de imagem, relevo e bandas espectrais
- Informação estruturada de cobertura e uso do solo (UCT)
- Dados de radar e infravermelho para condições adversas

Dificuldade

Escassez de dados multimodais rotulados em termos de dificuldade de deslocamento para treinamento de modelos de visão computacional.

Modelo Único



Metodologia



**Segmentação
Semântica**


Vegetação



Corpos D'água



Urbanização



**Heurística
Computacional**

Onde paramos

Apresentação anterior

- Classificação por imagem no EuroSAT
- Arquitetura VGG reduzida, 5 épocas
- Acurácia de teste: 87,94%
- Localização indireta por Grad-CAM


87,94%

Acurácia de teste


Grad-CAM

Segmentação indireta


Highway — original




Highway — Grad-CAM



Residential — original




Residential — Grad-CAM




Limitações: Segmentação Indireta

- **Viés de Contexto:** Ativações em bordas e margens (contraste) em vez do corpo do objeto (ex: rios).
- **Falta de Garantia:** Após a convergência do modelo, não é garantido que as regiões mais relevantes para a previsão correspondem à estrutura geográfica real.

River — original



River — Grad-CAM



Objetivos atualizados

Objetivos específicos

- Desenvolver e avaliar modelo de segmentação semântica de UCT em resolução compatível com imagem orbital gratuita
- Construir, de forma reprodutível, conjunto anotado em nível de pixel para um bioma brasileiro
- Adaptar o modelo ao domínio brasileiro por transferência de aprendizado
- Integrar o mapa de classes ao estimador de trafegabilidade existente

Pampa

Área de estudo

2 m/px

Resolução


6

Classes

~100

Imagens a anotar


Metodologia



Segmentação semântica e U-Net

Predição densa

- Uma classe por pixel, não por imagem
- Encoder extrai o quê, decoder recupera o onde
- Skip connections devolvem o detalhe do pooling
- Encoder EfficientNetB0 pré-treinado



Base DeepGlobe e escala de trabalho

Conjunto e preparação

- 803 imagens anotadas, 0,5 m/px, 7 classes
- Reamostragem para 2 m: treinar na escala de inferência
- Grade 3×3 sobreposta: 9 blocos de 256 px por imagem
- Divisão em nível de imagem: 6.147 / 1.080 blocos

Taxonomia de trabalho

	Urban
	Agriculture + Rangeland
	Forest
	Water
	Barren
	Unknown

-1,9 p.p.

Custo da reamostragem em IoU-4

16×

Mais contexto por bloco


66,8%

Participação da classe agregada


Fusão de classes: Agriculture + Rangeland

Evidência medida

- Rangeland: IoU 45,41%, metade da penúltima classe
- Único recall abaixo de 80%
- 20,1% de seus pixels vão para Agriculture
- Sentido inverso: apenas 2,8%
- Classe agregada resultante: IoU 90,15%



Série de experimentos: o que move a métrica



Diagnóstico

- Otimização: 0,35 p.p. de amplitude
- Dados: as três únicas variações
- Limitado por dados, não por configuração

0,35 p.p.

Amplitude das 4 intervenções de otimização

3 de 3

Ganhos vieram de mudanças de dados


Modelo base sobre o DeepGlobe

Desempenho por classe (validação)

Agriculture + Rangeland	90.15%
Water	84.21%
Forest	81.47%
Urban	76.30%
Barren	74.12%

Média das cinco classes presentes: 81,25%

mIoU declarada de 67,71% é distorcida pela classe ausente



Domínio alvo: CBERS-4A

O insumo e seus limites

- Única fonte gratuita de resolução métrica sobre o território brasileiro
- Produto fundido distribuído pelo INPE: resolução efetiva de cerca de 8 m em grade de 2 m
- Fusão refeita localmente a partir das bandas de nível 4, com realce por cena
- Pancromática abrange o infravermelho próximo, o que restringe os métodos de fusão aplicáveis

2 m

Resolução nominal

~8 m


Efetiva no produto do INPE

0,45–0,90 μm


Faixa da pancromática

Área de estudo e grade de imagens

- Bioma Pampa, porção gaúcha • 44 cenas, uma por órbita e ponto, em janela de inverno
- Grade de 1024 px (2048 m), desduplicada entre cenas e recortada pelo limite do bioma • 49.635 imagens candidatas



área de estudo, com o setor ampliado




grade no setor destacado

Estratificação da amostra


12 estratos

- MapBiomas como sinal auxiliar antes da anotação
- Seis classes, subdivididas onde há ponto cego
- Água é dominada pelas lagoas: rios ficariam de fora
- Urbano é dominado por Porto Alegre
- Quatro ordens de grandeza entre o maior e o menor



40,25%

Maior estrato: Agriculture



0,0015%

Menor estrato: Aquaculture

Alocação da amostra

Três requisitos

- Cobertura de todo estrato
- Proporcionalidade do restante
- Estabilidade de prefixo

Dois mecanismos

- Cota mínima com filtro de pureza
- Método dos divisores de Sainte-Laguë
- Listas embaralhadas por semente fixa

Por que não cotas com arredondamento

O método dos divisores é aditivo: nunca revê uma atribuição anterior. Ampliar o orçamento de anotação estende a sequência sem alterá-la, o que o arredondamento por maiores restos não garante, por estar sujeito ao paradoxo do Alabama.

Estado atual e próximos passos

Concluído

- Modelo base sobre DeepGlobe
- Seleção de 44 cenas
- Grade de 49.635 imagens
- Raster de 12 estratos

Em curso

- Campanha de anotação
- Fixação de cotas e limiares
- Documentação


A seguir

- Ajuste fino do modelo
- Validação cruzada por cena
- Integração ao estimador
- Mapa de dificuldade

Trabalho paralelo: reservatório quântico

Estudo de ablação

- Aceito no CBCTQ 2026
- PCA+MLP contra PCA+QRC+MLP no EuroSAT
- Linha de base clássica vence em MSE e SSIM
- Efeito pequeno, mas significativo em todo σ
- Causa: gargalo de 18 componentes



Trabalho paralelo: reservatório com passeio quântico (CTQW)

Contexto

- **Mesmo arcabouço** do slide anterior (QRC): reservatório fixo + leitura treinada.
- **Núcleo diferente:** passeio quântico em tempo contínuo sobre um grafo, em vez de qubits interagentes.
- **Pesquisa paralela** com bolsa (CNPq), orientação Cel Anderson.
- **Método validado** em artigo submetido ao II WQuSec (SBSEG 2026): no digits, QRC 97,0% > random features 95,4%.

Por que o núcleo importa

- **Qubits interagentes:** simulação custa memória $2^N \rightarrow$ gargalo de PCA com 18 componentes.
- **CTQW:** estado vive nos N vértices do grafo $\rightarrow$ custo $O(N^2)$, a imagem entra direto, sem PCA.
- Aplicado ao mesmo EuroSAT do PFC, na tarefa de classificação de UCT.

Pergunta central: a dinâmica quântica cria características úteis para classificar — ou qualquer projeção aleatória não linear produziria o mesmo efeito?


Antes do EuroSAT: o método provado em dois conjuntos

circles — prova de não linearidade

- **Leitura linear direta:** 49% (acaso — anéis concêntricos não se separam por reta).
- **Mesma leitura sobre o reservatório:** 85% — a não linearidade vem da dinâmica.
- **Honestidade:** random features também resolvem (99%) — isto prova não linearidade, não superioridade.

digits — vitória do sketch quântico

- **QRC puro:** 97,0% de acurácia de teste.
- **Random features do mesmo tamanho:** 95,4% — o reservatório vence o controle clássico direto.



Projeção PCA: no espaço original (esq.) as classes se sobrepõem; no espaço do reservatório (dir.) tornam-se separáveis.

Método: quatro fases, nenhum parâmetro quântico treinado

1 · Entrada

Imagem comprimida (8×8) vira vetor x padronizado (estatísticas só do treino).

2 · Codificação de fase

x vira o estado inicial: informação nas fases, escala $\pi/(4d^{1/2})$ mantém as fases bem-comportadas.

3 · Evolução CTQW

$U = e^{(-iHt)}$, H = adjacência do grafo.
Unitariedade verificada em toda execução.

4 · Medição + leitura

Probabilidades de ocupação dos N vértices → regressão logística (única parte treinada).

Desenho experimental: 4 conjuntos de características, mesma leitura

- **baseline** (pixels crus)
- **qrc_ctqw** (só o reservatório)
- **concat $[x, r(x)]$**
- **random features** (controle clássico: projeção aleatória não linear, $\gamma = 1/d$)

Split estratificado 70/30 (dataset completo: 18.900 treino / 8.100 teste), semente fixa; métricas de acurácia e F1 macro sempre no teste.

Resultados no EuroSAT: o que vence e o que aprendemos

67,7%

melhor resultado: tripla $[x, r(x), z(x)]$

61,2 vs 61,0

QRC puro vence RF (sketch vs sketch)

40,6 vs 39,5

cinza quadrático: QRC vence RF

27.000

imagens (10 classes; acaso 10%)

A leitura honesta dos experimentos

- **O reservatório sempre supera os pixels crus** (+6 a +10 pp) e, sketch contra sketch do mesmo tamanho, vence o controle clássico.
- **A dinâmica é um hiperparâmetro:** Erdős–Rényi supera o grafo completo; a leitura quadrática destrava o QRC no regime de poucas amostras.
- **Controle extra que nós mesmos adicionamos:** concat com random features $[x, z(x)]$ faz 67,2% — o ganho da concatenação é majoritariamente genérico, não específico do quântico.
- **Melhor resultado: 67,7% com a tripla $[x, r(x), z(x)]$** — e a tripla só com aleatórias $[x, z_1, z_2]$ fica em 67,2%: o complemento do reservatório é pequeno, mas específico dele.

Robustez, contraste entre os núcleos e integração ao PFC

E sem compressão? ($8 \times 8 \rightarrow 64 \times 64$ cru)

- **Todos os métodos rasos pioram** com a resolução (baseline: 42,7% $\rightarrow$ 29,9%).
- **O QRC quase não cai** (56,3% $\rightarrow$ 51,4%) e no 64×64 cru é o melhor dos quatro — acima do controle clássico (49,4%).
- O gargalo de N probabilidades atua como regularização natural.

Os dois núcleos, lado a lado

- **Qubits (denoising):** gargalo $2^N \rightarrow$ baseline clássica vence por pouco.
- **CTQW (classificação):** sem gargalo $\rightarrow$ vence o clássico nas comparações diretas (sketch contra sketch).
- **Próximo passo conjunto:** comparar os dois núcleos sob o mesmo protocolo (mesmo split, métricas e controles).

Integração ao PFC — primeiro teste feito: sobre features de uma CNN equivalente, o QRC preserva a informação em metade da dimensão (85,4% vs 85,6%), mas sem ganho mensurável (tudo em 85–86%).

Próximo passo: repetir com o modelo exato do PFC e comparar com o kernel do Paim no mesmo protocolo.

Cronograma

- **a)** Estudo e entendimento do PITCIC
- **b)** Exploração de conjuntos de dados amplamente disponíveis com informações de Uso e Cobertura da Terra (UCT)
- **c)** Treinamento do modelo base de classificação e definição do método de segmentação indireta
- **d)** Exploração de conjuntos de dados de segmentação para imagens de sensoriamento remoto
- **e)** Treinamento ou fine-tuning de modelo de segmentação
- **f)** Definição de heurística computacional baseada nas previsões do modelo de segmentação
- **g)** Aplicação do método proposto em dados visuais de Uso e Cobertura da Terra (UCT) do território brasileiro
- **h)** Documentação

Atividade	Mar	Abr	Mai	Jun	Jul	Ago	Set	Out
a								
b								
c								
d								
e								
f								
g								
h								